넷째마당
딥러닝 기본기 다지기

13장 모델 성능 검증하기

1 데이터의 확인과 예측 실행

2 과적합 이해하기

3 학습셋과 테스트셋

4 모델 저장과 재사용

5 k겹 교차 검증

모델 성능 검증하기

- 모델 성능 검증하기

모델 성능 검증하기

- **모델 성능 검증하기**
  - 1986년 제프리 힌튼 교수가 오차 역전파를 발표한 직후, 존스 홉킨스의 세즈노프스키(Sejnowski) 교수는 오차 역전파가 은닉층의 가중치를 실제로 업데이트시키는 것을 확인하고 싶었음
  - 그는 광석과 일반 암석에 수중 음파 탐지기를 쏜 후 결과를 모아 데이터셋을 준비했고, 음파 탐지기의 수신 결과만 보고 광석인지 일반 암석인지를 구분하는 모델을 만들었음
  - 그가 측정한 결과의 정확도는 몇이었을까?
  - 이 장에서는 세즈노프스키 교수가 했던 초음파 광물 예측 실험을 텐서플로로 재현해 보고, 이렇게 구해진 실험 정확도를 평가하는 방법과 성능을 향상시키는 중요한 머신 러닝 기법들에 대해 알아보자

1 데이터의 확인과 예측 실행

1 데이터의 확인과 예측 실행

- **데이터의 확인과 예측 실행**
  - 먼저 데이터를 불러와 첫 다섯 줄을 확인해 보자

```
# pandas 라이브러리를 불러옵니다.
import pandas as pd

# 깃허브에 준비된 데이터를 가져옵니다.
!git clone https://github.com/taehojo/data.git

# 광물 데이터를 불러옵니다.
df = pd.read_csv('./data/sonar3.csv', header=None)

df.head() # 첫 다섯 줄을 봅니다.
```

1 데이터의 확인과 예측 실행

- 데이터의 확인과 예측 실행

실행 결과

	0	1	2	3	4	5	...	55	56	57	58	59	60
0	0.0200	0.0371	0.0428	0.0207	0.0954	0.0986	...	0.0167	0.0180	0.0084	0.0090	0.0032	0
1	0.0453	0.0523	0.0843	0.0689	0.1183	0.2583	...	0.0191	0.0140	0.0049	0.0052	0.0044	0
2	0.0262	0.0582	0.1099	0.1083	0.0974	0.2280	...	0.0244	0.0316	0.0164	0.0095	0.0078	0
3	0.0100	0.0171	0.0623	0.0205	0.0205	0.0368	...	0.0073	0.0050	0.0044	0.0040	0.0117	0
4	0.0762	0.0666	0.0481	0.0394	0.0590	0.0649	...	0.0015	0.0072	0.0048	0.0107	0.0094	0

5 rows × 61 columns

1 데이터의 확인과 예측 실행

- **데이터의 확인과 예측 실행**
  - 전체가 61개의 열로 되어 있고, 마지막 열이 광물의 종류를 나타냄
  - 일반 암석일 경우 0, 광석일 경우 1로 표시되어 있음
  - 첫 번째 열부터 60번째 열까지는 음파 주파수의 에너지를 0에서 1 사이의 숫자로 표시하고 있음
  - 이제 일반 암석과 광석이 각각 몇 개나 포함되어 있는지 알아보자

```
df[60].value_counts()
```

1 데이터의 확인과 예측 실행

- 데이터의 확인과 예측 실행

실행 결과

```
1    111
0     97
Name: 60, dtype: int64
```

1 데이터의 확인과 예측 실행

- **데이터의 확인과 예측 실행**
  - 광석이 111개, 일반 암석이 97개, 총 208개의 샘플이 준비되어 있는 것을 알 수 있음
  -

```
X = df.iloc[:,0:60]
y = df.iloc[:,60]
```

1 데이터의 확인과 예측 실행

- **데이터의 확인과 예측 실행**
  - 이후 앞서 했던 그대로 딥러닝을 실행

실습 | 초음파 광물 예측하기: 데이터 확인과 실행

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

# 모델을 설정합니다.
model = Sequential()
model.add(Dense(24, input_dim=60, activation='relu'))
```

1 데이터의 확인과 예측 실행

- 데이터의 확인과 예측 실행

```
model.add(Dense(10, activation='relu'))
model.add(Dense(1, activation='sigmoid'))

# 모델을 컴파일합니다.
model.compile(loss='binary_crossentropy', optimizer='adam',
metrics=['accuracy'])

# 모델을 실행합니다.
history = model.fit(X, y, epochs=200, batch_size=10)
```

1 데이터의 확인과 예측 실행

- 데이터의 확인과 예측 실행

실행 결과

```
Epoch 1/200
21/21 [==============================] - 4s 4ms/step - loss: 0.6951 -
accuracy: 0.5000
... (중략) ...
Epoch 200/200
21/21 [==============================] - 0s 2ms/step - loss: 0.0327 -
accuracy: 1.0000
```

1 데이터의 확인과 예측 실행

- **데이터의 확인과 예측 실행**
  - 200번 반복되었을 때의 결과를 보니 정확도가 100%
  - 정말로 어떤 광물이든 100%의 확률로 판별해 내는 모델이 만들어진 것일까?
  - 다음 장을 보기 바람

2 과적합 이해하기

2 과적합 이해하기

- **과적합 이해하기**
  - 이제 과적합 문제가 무엇인지 알아보고 이를 어떻게 해결하는지 살펴보자
  - **과적합**(overfitting)이란 모델이 학습 데이터셋 안에서는 일정 수준 이상의 예측 정확도를 보이지만, 새로운 데이터에 적용하면 잘 맞지 않는 것을 의미
  - 그림 13-1의 그래프에서 빨간색 선을 보면 주어진 샘플에 정확히 맞게끔 그어져 있음
  - 이 선은 너무 주어진 샘플에만 최적화되어 있음
  - 지금 그어진 선을 새로운 데이터에 적용하면 정확한 분류가 어려워진다는 의미

2 과적합 이해하기

▼ 그림 13-1 | 과적합이 일어난 경우(빨간색)와 학습이 제대로 이루어지지 않은 경우(초록색)

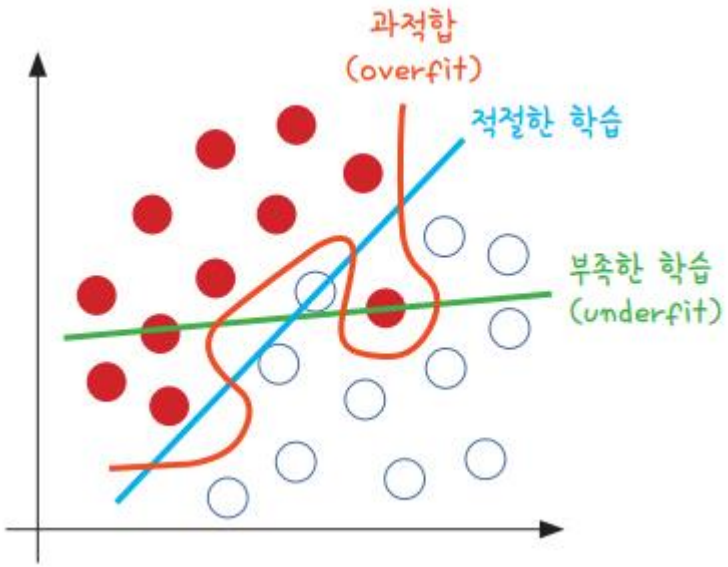

2 과적합 이해하기

- **과적합 이해하기**
  - 과적합은 층이 너무 많거나 변수가 복잡해서 발생하기도 하고 테스트셋과 학습셋이 중복될 때 생기기도 함
  - 특히 딥러닝은 학습 단계에서 입력층, 은닉층, 출력층의 노드들에 상당히 많은 변수가 투입
  - 딥러닝을 진행하는 동안 과적합에 빠지지 않게 늘 주의해야 함

3 학습셋과 테스트셋

3 학습셋과 테스트셋

- **학습셋과 테스트셋**
  - 그렇다면 과적합을 방지하려면 어떻게 해야 할까?
  - 먼저 학습을 하는 데이터셋과 이를 테스트할 데이터셋을 완전히 구분한 후 학습과 동시에 테스트를 병행하며 진행하는 것이 한 방법
  - 예를 들어 데이터셋이 총 100개의 샘플로 이루어져 있다면 다음과 같이 두 개의 셋으로 나눔

▼ **그림 13-2 | 학습셋과 테스트셋의 구분**

3 학습셋과 테스트셋

- **학습셋과 테스트셋**
  - 신경망을 만들어 70개의 샘플로 학습을 진행한 후 이 학습의 결과를 저장
  - 이렇게 저장된 파일을 '모델'이라고 함
  - 모델은 다른 셋에 적용할 경우 학습 단계에서 각인되었던 그대로 다시 수행
  - 나머지 30개의 샘플로 실험해서 정확도를 살펴보면 학습이 얼마나 잘되었는지 알 수 있는 것
  - 딥러닝 같은 알고리즘을 충분히 조절해 가장 나은 모델이 만들어지면, 이를 실생활에 대입해 활용하는 것이 바로 머신 러닝의 개발 순서

3 학습셋과 테스트셋

▼ 그림 13-3 | 학습셋과 테스트셋

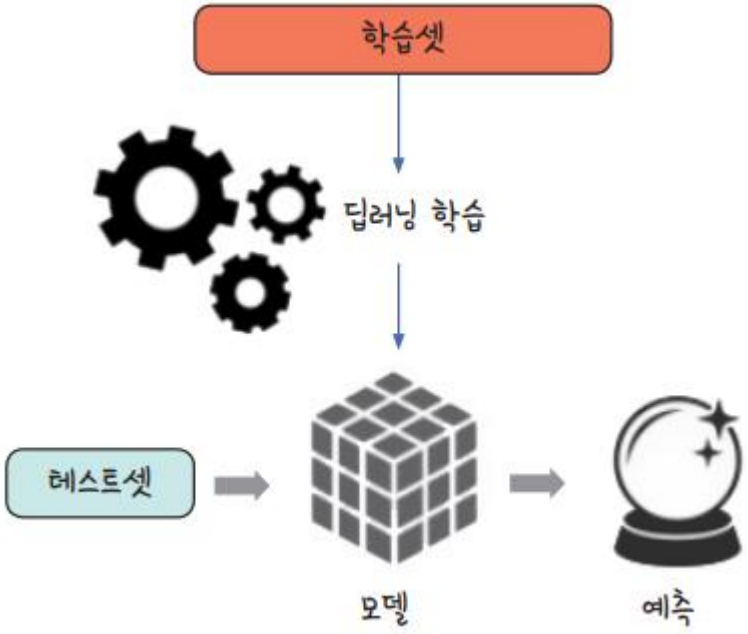

3 학습셋과 테스트셋

- **학습셋과 테스트셋**
  - 지금까지 우리는 테스트셋을 만들지 않고 학습해 왔음
  - 매번 정확도(accuracy)를 계산할 수 있었음
  - 어째서 가능했을까?
  - 지금까지 학습 데이터를 이용해 정확도를 측정한 것은 데이터에 들어 있는 모든 샘플을 그대로 테스트에 활용한 결과
  - 이를 통해 학습이 진행되는 상황을 파악할 수는 있지만, 새로운 데이터에 적용했을 때 어느 정도의 성능이 나올지는 알 수 없음
  - 머신 러닝의 최종 목적은 과거의 데이터를 토대로 새로운 데이터를 예측하는 것
  - 즉, 새로운 데이터에 사용할 모델을 만드는 것이 최종 목적이므로 테스트셋을 만들어 정확한 평가를 병행하는 것이 매우 중요

3 학습셋과 테스트셋

- **학습셋과 테스트셋**
  - 학습셋만 가지고 평가할 때, 층을 더하거나 에포크(epoch) 값을 높여 실행 횟수를 늘리면 정확도가 계속해서 올라갈 수 있음
  - 학습 데이터셋만으로 평가한 예측 성공률이 테스트셋에서도 그대로 나타나지는 않음
  - 즉, 학습이 깊어져 학습셋 내부에서 성공률은 높아져도 테스트셋에서는 효과가 없다면 과적합이 일어나고 있는 것
  - 이를 그래프로 표현하면 그림 13-4와 같음

3 학습셋과 테스트셋

▼ 그림 13-4 | 학습이 계속되면 학습셋에서의 에러는 계속해서 작아지지만, 테스트셋에서는
과적합이 발생!

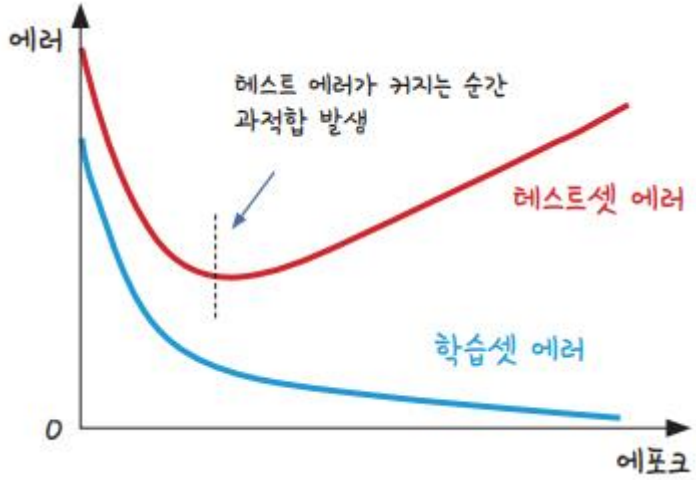

3 학습셋과 테스트셋

- **학습셋과 테스트셋**
  - 학습을 진행해도 테스트 결과가 더 이상 좋아지지 않는 지점에서 학습을 멈추어야 함
  - 이때 학습 정도가 가장 적절한 것으로 볼 수 있음
  - 우리가 다루는 초음파 광물 예측 데이터를 만든 세즈노프스키 교수가 실험 결과를 발표한 논문의 일부를 가져와 보자

▼ **그림 13-5 | 학습셋과 테스트셋 정확도 측정의 예(RP Gorman et.al., 1998)**

TABLE 2
Aspect-Angle Dependent Series

Number of Hidden Units	Average Performance on Training Sets (%)	Standard Deviation on Training Sets (%)	Average Performance on Testing Sets (%)	Standard Deviation on Testing Sets (%)
0	79.3	3.4	73.1	4.8
2	96.2	2.2	85.7	6.3
3	98.1	1.5	87.6	3.0
6	99.4	0.9	89.3	2.4
12	99.8	0.6	90.4	1.8
24	100.0	0.0	89.2	1.4

Summary of the results of the aspect-angle dependent series of experiments with training and testing sets selected to include all target aspect angles. The standard deviation shown is across networks with different initial conditions.

3 학습셋과 테스트셋

- **학습셋과 테스트셋**
  - 여기서 눈여겨보아야 할 부분은 은닉층(Number of Hidden Units) 개수가 올라감에 따라 학습셋의 예측률(Average Performance on Training Sets)과 테스트셋의 예측률(Average Performance on Testing Sets)이 어떻게 변하는지임
  - 이 부분만 따로 뽑아 정리하면 표 13-1과 같음

▼ **표 13-1 | 은닉층 개수의 변화에 따른 학습셋 및 테스트셋의 예측률**

은닉층 개수의 변화	학습셋의 예측률	테스트셋의 예측률
0	79.3	73.1
2	96.2	85.7
3	98.1	87.6
6	99.4	89.3
12	99.8	90.4
24	100	89.2

3 학습셋과 테스트셋

- **학습셋과 테스트셋**
  - 은닉층이 늘어날수록 학습셋의 예측률이 점점 올라가다가 결국 24개의 층에 이르면 100% 예측률을 보임
  - 우리가 조금 전 실행했던 것과 같은 결과!
  - 이 모델을 토대로 테스트한 결과는 어떤가?
  - 테스트셋 예측률은 은닉층의 개수가 12개일 때 90.4%로 최고를 이루다 24개째에서는 다시 89.2%로 떨어지고 맘
  - 즉, 식이 복잡해지고 학습량이 늘어날수록 학습 데이터를 통한 예측률은 계속해서 올라가지만, 적절하게 조절하지 않을 경우 테스트셋을 이용한 예측률은 오히려 떨어지는 것을 확인할 수 있음
  - 예제에 주어진 데이터를 학습셋과 테스트셋으로 나누는 예제를 만들어 보자

3 학습셋과 테스트셋

- **학습셋과 테스트셋**
  - 이 실습에는 사이킷런(scikit-learn) 라이브러리가 필요함
  - 코랩은 기본으로 제공하지만, 주피터 노트북을 이용해서 실습 중이라면 다음 명령으로 사이킷런 라이브러리를 설치해야 함
  - 사이킷런은 파이썬으로 머신 러닝을 실행할 때 필요한 전반적인 것들이 담긴 머신 러닝의 필수 라이브러리

```
!pip install sklearn
```

3 학습셋과 테스트셋

- **학습셋과 테스트셋**
  - 저장된 X 데이터와 y 데이터에서 각각 정해진 비율(%)만큼 학습셋과 테스트셋으로 분리시키는 함수가 사이킷런의 train_test_split() 함수
  - 다음과 같이 학습셋과 테스트셋을 만들 수 있음
  - 학습셋을 70%, 테스트셋을 30%로 설정했을 때의 예

```
from sklearn.model_selection import train_test_split

# 학습셋과 테스트셋을 구분합니다.
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,
shuffle=True)
```

3 학습셋과 테스트셋

- **학습셋과 테스트셋**
  - test_size는 테스트셋의 비율을 나타냄
  - 0.3은 전체 데이터의 30%를 테스트셋으로 사용하라는 것으로, 나머지 70%를 학습셋으로 사용하게 됨
  - 이렇게 나누어진 학습셋과 테스트셋은 각각 X_train, X_test, y_train, y_test로 저장
  - 모델은 앞서 만든 구조를 그대로 유지하고 대신 모델에 테스트 함수를 추가
  - 만들어진 모델을 테스트셋에 적용하려면 model.evaluate() 함수를 사용하면 됨

```
score = model.evaluate(X_test, y_test)
print('Test accuracy:', score[1])
```

3 학습셋과 테스트셋

- **학습셋과 테스트셋**
  - model.evaluate() 함수는 loss와 accuracy, 두 가지를 계산해 출력
  - 이를 score로 저장하고 accuracy를 출력하도록 범위를 정했음
  - 함수 내부에는 테스트셋 정보를 집어넣음

3 학습셋과 테스트셋

- **학습셋과 테스트셋**
  - 이제 전체 코드를 실행해 보자

실습 | 초음파 광물 예측하기: 학습셋과 테스트셋 구분

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense
from sklearn.model_selection import train_test_split

import pandas as pd

# 깃허브에 준비된 데이터를 가져옵니다.
!git clone https://github.com/taehojo/data.git

# 광물 데이터를 불러옵니다.
df = pd.read_csv('./data/sonar3.csv', header=None)
```

3 학습셋과 테스트셋

- 학습셋과 테스트셋

```
# 음파 관련 속성을 X로, 광물의 종류를 y로 저장합니다.
X = df.iloc[:,0:60]
y = df.iloc[:,60]

# 학습셋과 테스트셋을 구분합니다.
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,
shuffle=True)

# 모델을 설정합니다.
model = Sequential()
model.add(Dense(24, input_dim=60, activation='relu'))
model.add(Dense(10, activation='relu'))
model.add(Dense(1, activation='sigmoid'))
```

3 학습셋과 테스트셋

- 학습셋과 테스트셋

```
# 모델을 컴파일합니다.
model.compile(loss='binary_crossentropy', optimizer='adam',
metrics=['accuracy'])

# 모델을 실행합니다.
history = model.fit(X_train, y_train, epochs=200, batch_size=10)

# 모델을 테스트셋에 적용해 정확도를 구합니다.
score = model.evaluate(X_test, y_test)
print('Test accuracy:', score[1])
```

3 학습셋과 테스트셋

- 학습셋과 테스트셋

실행 결과

```
Epoch 1/200
15/15 [==============================] - 0s 3ms/step - loss: 0.7158 -
accuracy: 0.4828
... (중략) ...
Epoch 200/200
15/15 [==============================] - 0s 2ms/step - loss: 0.0590 -
accuracy: 0.9931
```

❶

```
2/2 [==============================] - 0s 2ms/step - loss: 0.4214 -
accuracy: 0.8413
Test accuracy: 0.841269850730896
```

❷

3 학습셋과 테스트셋

- **학습셋과 테스트셋**
  - 두 가지를 눈여겨보아야 함
  - 첫째는 학습셋(X_train과 y_train)을 이용해 200번의 학습을 진행했을 때 정확도가 99.31%라는 것❶)
  - 따로 저장해 둔 테스트셋(X_test와 y_test)에 이 모델을 적용하면 84.12%의 정확도❷를 보여 줌( )

3 학습셋과 테스트셋

- **학습셋과 테스트셋**
  - 딥러닝, 머신 러닝의 목표는 학습셋에서만 잘 작동하는 모델을 만드는 것이 아님
  - 새로운 데이터에 대해 높은 정확도를 안정되게 보여 주는 모델을 만드는 것이 목표
  - 어떻게 하면 이러한 모델을 만들 수 있을까?
  - 모델 성능의 향상을 위한 방법에는 크게 데이터를 보강하는 방법과 알고리즘을 최적화하는 방법이 있음
  - 데이터를 이용해 성능을 향상시키려면 우선 충분한 데이터를 가져와 추가하면 됨
  - 많이 알려진 다음 그래프는 특히 딥러닝의 경우 샘플 수가 많을수록 성능이 좋아짐을 보여 줌

3 학습셋과 테스트셋

▼ 그림 13-6 | 데이터의 증가와 딥러닝, 머신 러닝 성능의 상관관계

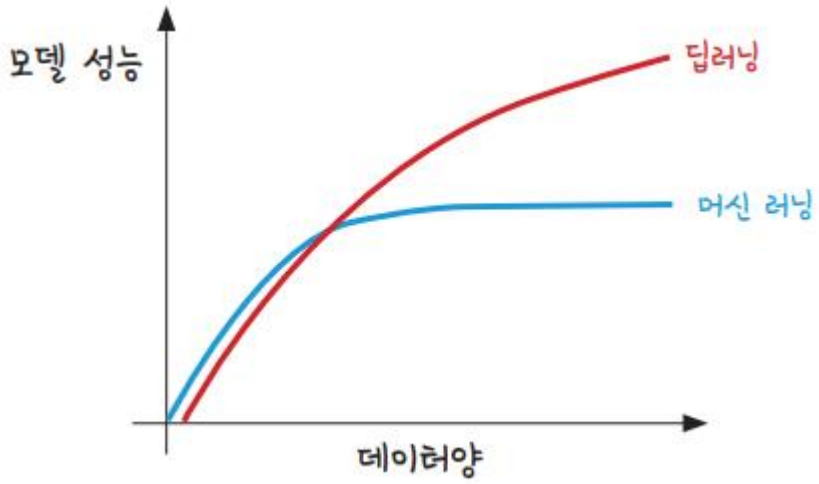

3 학습셋과 테스트셋

- **학습셋과 테스트셋**
  - 데이터를 추가하는 것 자체가 어렵거나 데이터 추가만으로는 성능에 한계가 있을 수 있음
  - 가지고 있는 데이터를 적절히 보완해 주는 방법을 사용
  - 예를 들어 사진의 경우 사진 크기를 확대/축소한 것을 더해 보거나 위아래로 조금씩 움직여 넣어 보는 것
  - 테이블형 데이터의 경우 너무 크거나 낮은 이상치가 모델에 영향을 줄 수 없도록 크기를 적절히 조절할 수 있음
  - 시그모이드 함수를 사용해 전체를 0~1 사이의 값으로 변환하는 것이 좋은 예
  - 또 교차 검증 방법을 사용해 가지고 있는 데이터를 충분히 이용하는 방법도 있음

3 학습셋과 테스트셋

- **학습셋과 테스트셋**
  - 다음으로 알고리즘을 이용해 성능을 향상하는 방법은 먼저 다른 구조로 모델을 바꾸어 가며 최적의 구조를 찾는 것
  - 예를 들어 은닉층의 개수라든지, 그 안에 들어갈 노드의 수, 최적화 함수의 종류를 바꾸어 보는 것
  - 앞서 이야기한 바 있지만, 딥러닝 설정에 정답은 없음
  - 자신의 데이터에 꼭 맞는 구조를 계속해서 테스트해 보며 찾는 것이 중요
  - 데이터에 따라서는 딥러닝이 아닌 랜덤 포레스트, XGBoost, SVM 등 다른 알고리즘이 더 좋은 성과를 보일 때도 있음
  - 일반적인 머신 러닝과 딥러닝을 합해서 더 좋은 결과를 만드는 것도 가능
  - 많은 경험을 통해 최적의 성능을 보이는 모델을 만드는 것이 중요

4 모델 저장과 재사용

4 모델 저장과 재사용

- **모델 저장과 재사용**
  - 학습이 끝난 후 지금 만든 모델을 저장하면 언제든 이를 불러와 다시 사용할 수 있음
  - 학습 결과를 저장하려면 ... 학습을 이용해 모델 이름을 정의 저장

```
# 모델 이름과 저장할 위치를 함께 지정합니다.
model.save('./data/model/my_model.hdf5')
```

4 모델 저장과 재사용

- **모델 저장과 재사용**
  - hdf5 파일 포맷은 주로 과학 기술 데이터 작업에서 사용되는데, 크고 복잡한 데이터를 저장하는 데 사용
  - 이를 다시 불러오려면 케라스 API의 load_model 함수를 사용
  - 앞서 Sequential 함수를 불러온 모델 클래스 안에 함께 들어 있으므로, Sequential 뒤에 load_model을 추가해 다시 불러옴

```
from tensorflow.keras.models import Sequential, load_model
                                                  ❶
```

4 모델 저장과 재사용

- **모델 저장과 재사용**
  - 테스트를 위해 조금 전 만든 모델을 메모리에서 삭제

```
del model
```

4 모델 저장과 재사용

- **모델 저장과 재사용**
  - load_model() 함수를 사용해서 조금 전 저장한 모델을 불러옴

```
# 모델이 저장된 위치와 이름까지 적어 줍니다.
model = load_model('./data/model/my_model.hdf5')
```

4 모델 저장과 재사용

- **모델 저장과 재사용**
  - 불러온 모델을 테스트셋에 적용해 정확도를 구함

```
score = model.evaluate(X_test, y_test)
print('Test accuracy:', score[1])
```

4 모델 저장과 재사용

- 모델 저장과 재사용

실행 결과

```
2/2 [==============================] - 0s 2ms/step - loss: 0.4214 -
accuracy: 0.8413
Test accuracy: 0.841269850730896
```

  - 이전 절에서 실행한 것과 같은 값이 나오는 것을 확인할 수 있음

5 k겹 교차 검증

5 k겹 교차 검증

- **k겹 교차 검증**
  - 앞서 데이터가 충분히 많아야 모델 성능도 향상된다고 했음
  - 이는 학습과 테스트를 위한 데이터를 충분히 확보할수록 세상에 나왔을 때 더 잘 작동하기 때문임
  - 실제 프로젝트에서는 데이터를 확보하는 것이 쉽지 않거나 많은 비용이 발생하는 경우도 있음
  - 가지고 있는 데이터를 십분 활용하는 것이 중요
  - 특히 학습셋을 70%, 테스트셋을 30%로 설정할 경우 30%의 테스트셋은 학습에 이용할 수 없다는 단점이 있음
  - 이를 해결하기 위해 고안된 방법이 k겹 교차 검증(k-fold cross validation)

5 k겹 교차 검증

- **k겹 교차 검증**
  - k겹 교차 검증이란 데이터셋을 여러 개로 나누어 하나씩 테스트셋으로 사용하고 나머지를 모두 합해서 학습셋으로 사용하는 방법
  - 이렇게 하면 가지고 있는 데이터의 100%를 학습셋으로 사용할 수 있고, 또 동시에 테스트셋으로도 사용할 수 있음
  - 예를 들어 5겹 교차 검증(5-fold cross validation)의 예가 그림 13-7에 설명되어 있음

5 k겹 교차 검증

▼ 그림 13-7 | 5겹 교차 검증의 도식

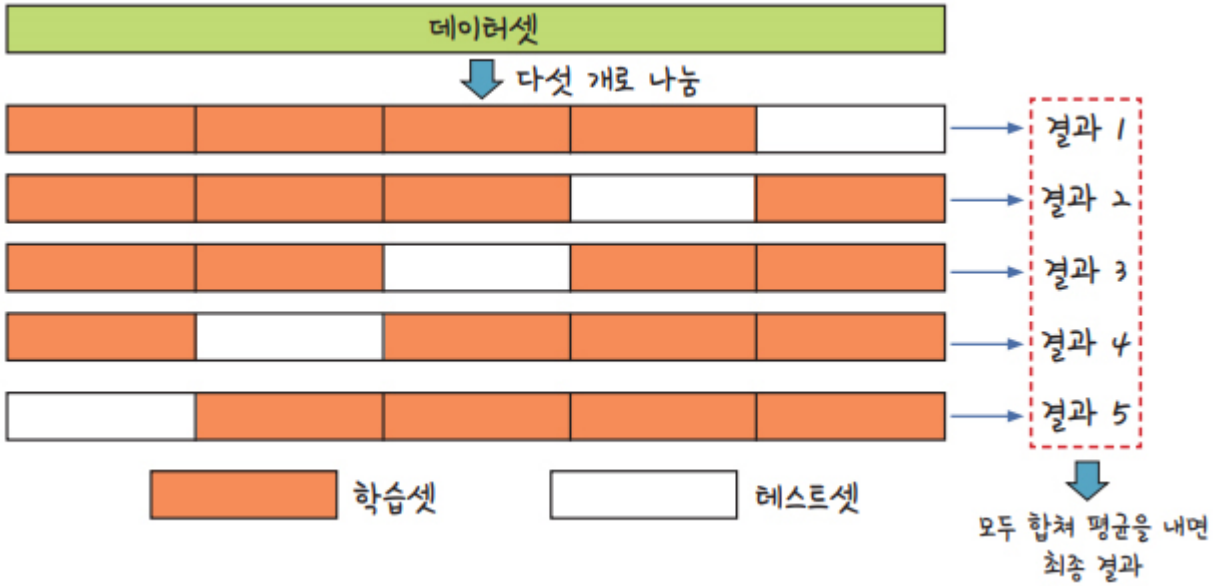

5 k겹 교차 검증

- **k겹 교차 검증**
  - k데이터셋을 다섯 개로 나눈 후 그중 네 개를 학습셋으로, 나머지 하나를 테스트셋으로 만들어 다섯 번의 학습을 순차적으로 실시하는 것이 5겹 교차 검증
  - 이제 초음파 광물 예측 예제를 통해 5겹 교차 검증을 실시해 보자

5 k겹 교차 검증

- **k겹 교차 검증**
  - 데이터를 원하는 수만큼 나누어 각각 학습셋과 테스트셋으로 사용되게 하는 함수는 사이킷런 라이브러리의 KFold() 함수
  - 실습 코드에서 KFold()를 활용하는 부분만 뽑아 보면 다음과 같음

```
from sklearn.model_selection import KFold
k = 5 ····❶
kfold = KFold(n_splits=k, shuffle=True) ····❷
acc_score = [] ····❸

for train_index, test_index in kfold.split(X): ····❹
    X_train, X_test = X.iloc[train_index,:], X.iloc[test_index,:]
    y_train, y_test = y.iloc[train_index], y.iloc[test_index]
```

5 k겹 교차 검증

- **k겹 교차 검증**
  - 먼저 몇 개의 파일로 나눌 것인지 정해 ❶ k 변수에 넣음
  - 사이킷런의 ❷ KFold() 함수를 불러옴
  - 샘플이 어느 한쪽에 치우치지 않도록 shuffle 옵션을 True로 설정해 줌
  - 정확도가 채워질 ❸ acc_score라는 이름의 빈 리스트를 준비
  - ❹ split()에 의해 k개의 학습셋, 테스트셋으로 분리되며 for 문에 의해 k번 반복

5 k겹 교차 검증

- **k겹 교차 검증**
  - 반복되는 각 학습마다 정확도를 구해 다음과 같이 acc_score 리스트를 채움

```
accuracy = model.evaluate(X_test, y_test)[1] # 정확도를 구합니다.
acc_score.append(accuracy)                   # acc_score 리스트에 저장합니다.
```

  - k번의 학습이 끝나면 각 정확도들을 취합해 모델 성능을 평가

5 k겹 교차 검증

- **k겹 교차 검증**
  - 모든 코드를 모아 실행하면 다음과 같음

실습 | 초음파 광물 예측하기: k겹 교차 검증

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense
from sklearn.model_selection import KFold
from sklearn.metrics import accuracy_score

import pandas as pd

# 깃허브에 준비된 데이터를 가져옵니다.
!git clone https://github.com/taehojo/data.git
```

5 k겹 교차 검증

- k겹 교차 검증

```
# 광물 데이터를 불러옵니다.
df = pd.read_csv('./data/sonar3.csv', header=None)

# 음파 관련 속성을 X로, 광물의 종류를 y로 저장합니다.
X = df.iloc[:,0:60]
y = df.iloc[:,60]

# 몇 겹으로 나눌 것인지 정합니다.
k = 5

# KFold 함수를 불러옵니다. 분할하기 전에 샘플이 치우치지 않도록 섞어 줍니다.
kfold = KFold(n_splits=k, shuffle=True)
```

5 k겹 교차 검증

- k겹 교차 검증

```
# 정확도가 채워질 빈 리스트를 준비합니다.
acc_score = []

def model_fn():
    model = Sequential() # 딥러닝 모델의 구조를 시작합니다.
    model.add(Dense(24, input_dim=60, activation='relu'))
    model.add(Dense(10, activation='relu'))
    model.add(Dense(1, activation='sigmoid'))
    return model

# k겹 교차 검증을 이용해 k번의 학습을 실행합니다.
# for 문에 의해 k번 반복합니다.
```

5 k겹 교차 검증

- k겹 교차 검증

```
# split()에 의해 k개의 학습셋, 테스트셋으로 분리됩니다.
for train_index, test_index in kfold.split(X):
    X_train, X_test = X.iloc[train_index,:], X.iloc[test_index,:]
    y_train, y_test = y.iloc[train_index], y.iloc[test_index]

    model = model_fn()
    model.compile(loss='binary_crossentropy', optimizer='adam',
metrics=['accuracy'])
    history = model.fit(X_train, y_train, epochs=200, batch_size=10,
verbose=0)

    accuracy = model.evaluate(X_test, y_test)[1] # 정확도를 구합니다.
    acc_score.append(accuracy)                   # 정확도 리스트에 저장합니다.
```

5 k겹 교차 검증

- k겹 교차 검증

```
# k번 실시된 정확도의 평균을 구합니다.
avg_acc_score = sum(acc_score) / k

# 결과를 출력합니다.
print('정확도: ', acc_score)
print('정확도 평균: ', avg_acc_score)
```

5 k겹 교차 검증

- k겹 교차 검증

실행 결과

```
2/2 [==============================] - 0s 2ms/step - loss: 1.0080 -
accuracy: 0.7381
2/2 [==============================] - 0s 2ms/step - loss: 0.7071 -
accuracy: 0.8095
2/2 [==============================] - 0s 2ms/step - loss: 0.3312 -
accuracy: 0.8810
2/2 [==============================] - 0s 2ms/step - loss: 0.4377 -
accuracy: 0.9024
2/2 [==============================] - 0s 3ms/step - loss: 0.6416 - accura
cy: 0.7317
정확도: [0.738095223903656, 0.8095238208770752, 0.8809523582458496,
0.9024389982223511, 0.7317073345184326]
정확도 평균: 0.8125435471534729
```

5 k겹 교차 검증

- **k겹 교차 검증**
  - 다섯 번의 정확도를 구했음
  - 학습이 진행되는 과정이 길어서 model.fit 부분에 verbose=0 옵션을 주어 학습 과정의 출력을 생략

5 k겹 교차 검증

- **k겹 교차 검증**
  - 텐서플로 함수가 for 문에 포함되는 경우 다음과 같이 WARNING 메시지가 나오는 경우가 있음
  - 텐서플로 구동에는 문제가 없으므로 그냥 진행하면 됨

WARNING:tensorflow:5 out of the last 9 calls to <function Model.make_test_function.<locals>.test_function at 0x000001EDE50D60D0> triggered tf.function retracing...

5 k겹 교차 검증

- **k겹 교차 검증**
  - 이렇게 해서 가지고 있는 데이터를 모두 사용해 학습과 테스트를 진행
  - 이제 다음 장을 통해 학습 과정을 시각화해 보는 방법과 학습을 몇 번 반복할지(epochs) 스스로 판단하게 하는 방법 등을 알아보며 모델 성능을 향상시켜 보겠음